4. tjedan — Regularne perturbacije

28. listopada 2026.

Napomena o nastanku i korištenju nastavnih materijala

Ova predavanja nastala su na temelju autorovih rukom pisanih priprema za nastavu, koje su uz pomoć alata ChatGPT transkribirane, jezično uređene i oblikovane u LaTeX dokumente. ChatGPT je korišten i kao pomoć pri provjeri matematičkih izraza, izvoda i konzistentnosti oznaka. Unatoč provjerama, materijali mogu sadržavati matematičke, konceptualne ili druge pogreške, uključujući one nastale tijekom transkripcije i obrade pomoću umjetne inteligencije. **Od studenata se očekuje da sadržaju pristupaju kritički, samostalno provjeravaju matematičke izvode, pretpostavke i zaključke te ih uspoređuju s preporučenom literaturom.** Materijali su namijenjeni kao pomoć pri učenju, a ne kao zamjena za samostalno matematičko razmišljanje i razumijevanje.

1 Uvod

U mnogim matematičkim modelima pojavljuje se mali bezdimenzijski parametar ε. Ideja perturbacijske metode jest analizirati granicu $\varepsilon \to 0$ i tako složeni problem povezati s jednostavnijim graničnim problemom. Ako se rješenje može razviti u red potencija po ε i pritom se ne mijenja osnovna struktura problema, govorimo o *regularnoj perturbaciji*.

2 Nultočke polinoma

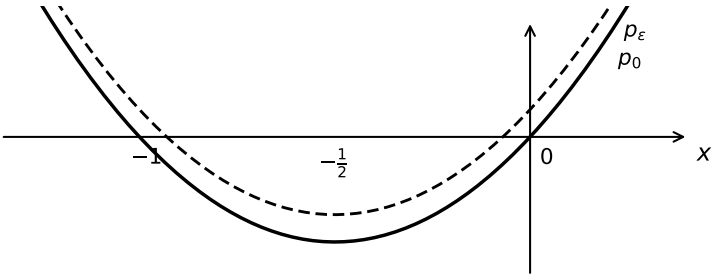
Tražimo nultočke polinoma

$$p_\varepsilon(x) = x^2 + x + \varepsilon, \qquad 0 < \varepsilon \ll 1. \tag{1}$$

Najprije promatramo jednostavniji problem za $\varepsilon = 0$:

$$p_0(x) = x^2 + x = x(x+1) = 0.$$

Njegove su nultočke $x_1 = 0$ i $x_2 = -1$, a vrh parabole nalazi se u točki $x = -\frac{1}{2}$, pri čemu je $p_0(-\frac{1}{2}) = -\frac{1}{4}$. Dodavanjem male pozitivne konstante ε parabola se pomiče prema gore. Očekujemo da će nultočka blizu nule postati malo negativna, a nultočka blizu -1 malo veća od -1, kao što pokazuje slika 1.



Slika 1: Puni graf p_0 i isprekidani graf p_ε za mali pozitivni ε.

2.1 Egzaktna formula i Taylorov razvoj

Rješenja jednadžbe $p_\varepsilon(x) = 0$ mogu se dobiti izravno formulom za nultočke kvadratne jednadžbe:

$$x_{1,2} = -\frac{1}{2} \pm \frac{1}{2}\sqrt{1-4\varepsilon}. \tag{2}$$

Za $0 < \varepsilon < \frac{1}{4}$ obje su nultočke realne i jednostavne. Kako bismo razumjeli njihov odnos prema malom parametru, koristimo Taylorov razvoj funkcije $f(t) = \sqrt{1+t}$ oko $t = 0$. Budući da vrijedi

$$f(0) = 1, \qquad f'(0) = \frac{1}{2}, \qquad f''(0) = -\frac{1}{4},$$

imamo

$$\sqrt{1+t} = 1 + \frac{t}{2} - \frac{t^2}{8} + O(t^3), \qquad t \to 0. \tag{3}$$

Uvrštavanjem $t = -4\varepsilon$ dobivamo

$$\begin{aligned} x_{1,2} &= -\frac{1}{2} \pm \frac{1}{2}\sqrt{1-4\varepsilon} \\ &= -\frac{1}{2} \pm \frac{1}{2}\big(1 - 2\varepsilon - 2\varepsilon^2 + O(\varepsilon^3)\big). \end{aligned}$$

Prema tome,

$$x_1 = -\varepsilon - \varepsilon^2 + O(\varepsilon^3), \qquad x_2 = -1 + \varepsilon + \varepsilon^2 + O(\varepsilon^3). \tag{4}$$

Vidimo da se rješenja mogu opisati potencijama malog parametra. Želimo sada dobiti isti rezultat bez upotrebe formule za nultočke.

2.2 Perturbacijski ansatz

Definicija 1 (Ansatz)**.** *Ansatz* je pretpostavljeni oblik rješenja kojim započinjemo analizu problema. U regularnoj perturbacijskoj metodi pretpostavljamo razvoj oblika

$$x(\varepsilon) = y_0 + y_1\varepsilon + y_2\varepsilon^2 + O(\varepsilon^3), \tag{5}$$

gdje su koeficijenti y_0, y_1, y_2 neovisni o ε.

Uvrštavanjem tog oblika u jednadžbu $x^2 + x + \varepsilon = 0$ dobivamo

$$\big(y_0 + y_1\varepsilon + y_2\varepsilon^2 + O(\varepsilon^3)\big)^2 + \big(y_0 + y_1\varepsilon + y_2\varepsilon^2 + O(\varepsilon^3)\big) + \varepsilon = 0.$$

Sređivanjem članova prema potencijama parametra ε slijedi

$$(y_0^2 + y_0) + \varepsilon(2y_0y_1 + y_1 + 1) + \varepsilon^2(y_1^2 + 2y_0y_2 + y_2) + O(\varepsilon^3) = 0. \tag{6}$$

Da bi jednadžba vrijedila do ostatka reda $O(\varepsilon^3)$, koeficijenti uz ε^0, ε^1 i ε^2 moraju biti jednaki nuli. Formalno izjednačavamo te koeficijente. Uz ε^0 dobivamo

$$y_0^2 + y_0 = 0 \quad \Longleftrightarrow \quad y_0(y_0 + 1) = 0,$$

pa postoje dvije mogućnosti: $y_0^{(1)} = 0$ i $y_0^{(2)} = -1$. Uz ε^1 dobivamo

$$2y_0y_1 + y_1 + 1 = 0 \quad \Longleftrightarrow \quad y_1 = -\frac{1}{2y_0 + 1},$$

odnosno $y_1^{(1)} = -1$ i $y_1^{(2)} = 1$. Konačno, uz ε^2 dobivamo

$$y_1^2 + 2y_0y_2 + y_2 = 0 \quad \Longleftrightarrow \quad y_2 = -\frac{y_1^2}{2y_0 + 1},$$

pa su $y_2^{(1)} = -1$ i $y_2^{(2)} = 1$.

Na taj način ponovno dobivamo dva asimptotska rješenja:

$$x_1 = -\varepsilon - \varepsilon^2 + O(\varepsilon^3), \qquad x_2 = -1 + \varepsilon + \varepsilon^2 + O(\varepsilon^3). \tag{7}$$

2.3 Opravdanost asimptotskog razvoja

Zašto pretpostavljamo da rješenje možemo zapisati u obliku potencijskog reda po parametru ε? Ako je rješenje $x(\varepsilon)$ analitička funkcija parametra u okolini $\varepsilon = 0$, takav razvoj slijedi iz Taylorova teorema. U našem primjeru analitička inačica teorema o implicitnoj funkciji osigurava analitičnost grana rješenja: za $F(x, \varepsilon) = x^2 + x + \varepsilon$ vrijedi

$$F_x(x, \varepsilon) = 2x + 1, \qquad F_x(0, 0) = 1 \neq 0, \qquad F_x(-1, 0) = -1 \neq 0.$$

Stoga rješenja za dovoljno male vrijednosti parametra možemo prikazati konvergentnim potencijskim redom, a njegove koeficijente odrediti uvrštavanjem u početnu jednadžbu i uspoređivanjem jednakih potencija parametra ε.

Važno je naglasiti da ovakav razvoj nije uvijek opravdan. Ako navedeni uvjeti nisu ispunjeni, rješenje ne mora biti analitička funkcija parametra pa se mogu pojaviti drukčiji asimptotski razvoji, primjerice oni koji uključuju necjelobrojne potencije. Čak i kada postoji formalni potencijski razvoj, njegova konvergencija ili asimptotska valjanost mora se zasebno opravdati.

Primjer 1 (Numerička usporedba)**.** Za $\varepsilon = 0{,}1$ dobivamo aproksimacije

$$x_1 \approx -0{,}1 - 0{,}01 = -0{,}11, \qquad x_2 \approx -1 + 0{,}1 + 0{,}01 = -0{,}89.$$

Točne vrijednosti iz kvadratne formule iznose $x_1 \approx -0{,}112702$ i $x_2 \approx -0{,}887298$. Apsolutne pogreške približno su jednake $2{,}7 \cdot 10^{-3}$. Ostatak je asimptotski reda $O(\varepsilon^3)$, a za $\varepsilon = 0{,}1$ vrijedi $\varepsilon^3 = 10^{-3}$. Oznaka $O(\varepsilon^3)$ sama po sebi ne tvrdi da je pogreška manja od 10^{-3} jer u definiciji postoji i nepoznata multiplikativna konstanta.